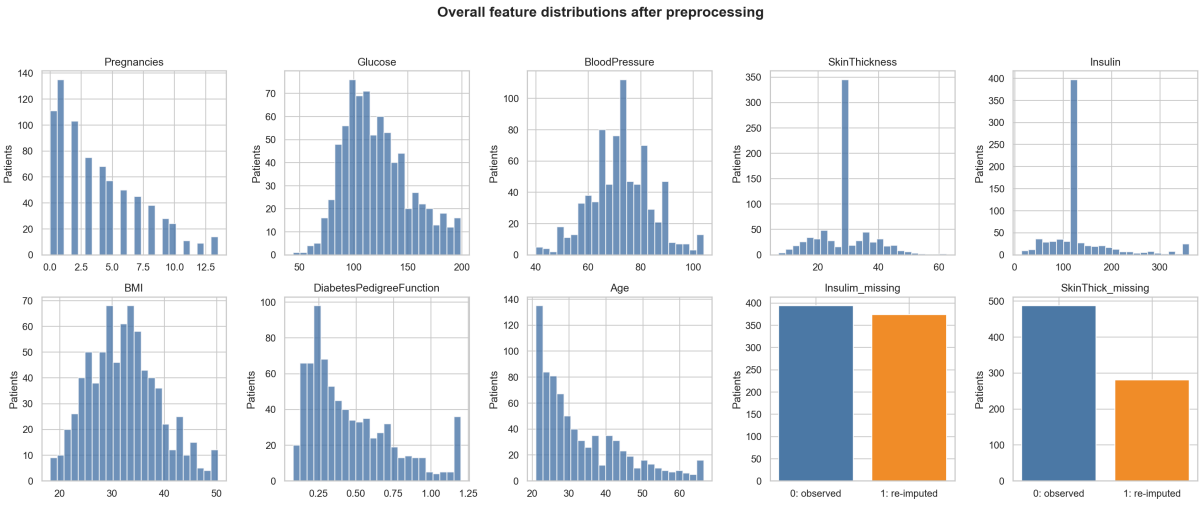
3주차

해야 할 일

1. 분류 데이터셋 업로드
2. 모델 성능 평가 준비
    a. “왜 이 모델이 내 데이터에 적합한지”

1. 데이터셋 분류

- 2주차까지 데이터셋에서 잘못 대치된 결측치들을 전체 데이터셋에 대한 중앙값으로 처리했습니다.
- 그러나 데이터 누수를 처리하려다 인위적인 이상치를 만들어낸 상황이 되었습니다.



SkinThickness , Insulin 두 변수에서 튀는 값 발생

- 다량의 결측치를 특정 단일 값(전체 중앙값) 으로 일괄 대치했기 때문입니다.
- Insulin_missing, SkinThickness_missing 과 같은 결측 여부 표시 변수를 추가했음에도 원래 변수인 Insulin, SkinThickness 의 분산과 타 변수들과의 상관관계는 오염됩니다.

- 따라서 전체 중앙값으로 일괄 대치된 원래 다량의 결측치들을 다시 결측치 NaN 상태로 되돌리고 데이터셋 재분류 했습니다.

2. 모델 성능 평가 준비

1. NaN 상태를 자체 분할하는 최신 트리 모델 3가지

① XGBoost (Sparsity-aware Split Finding)

- **작동 방식:** 학습 과정에서 특정 분할 기준 노드를 만났을 때, `NaN` 데이터를 오른쪽 자식 노드로 보냈을 때의 손실(Loss)과 왼쪽 자식 노드로 보냈을 때의 손실을 모두 계산해 봅니다.
- **특징:** 손실을 더 크게 줄여주는(성능이 더 좋아지는) 방향을 기본 방향(Default Direction)으로 자동 지정하여 결측치를 처리합니다.

② LightGBM (Default Direction Strategy)

- **작동 방식:** XGBoost와 유사하게 결측치를 가진 데이터를 분할 시 제외해 두고, 결측치가 없는 데이터들로 최적의 분할 지점(Split Point)을 찾습니다.
- **특징:** 이후 결측치 데이터 전체를 왼쪽과 오른쪽 노드 중 정보 이득(Information Gain)이 더 높은 쪽으로 일괄 배치합니다. 대용량 데이터 처리 속도가 매우 빠른 것이 특징입니다.

③ CatBoost (Min/Max Value Imputation & Target Encoding)

- **작동 방식:** 수치형 변수의 결측치는 기본적으로 해당 변수의 최소값보다 작거나 최대값보다 큰 극단값으로 가정하고 트리 분할을 시도합니다.
- **특징:** 범주형 변수의 결측치나 타깃 인코딩 시 결측치가 포함되어도 수치적/통계적으로 가장 안정적인 규칙을 찾아 자동으로 분할에 반영합니다.

---

2. 데이터 크기(700여 개 행) 관점에서의 비교 및 모델 선택

현재 보유하신 데이터셋은 약 700여 행의 소규모 데이터셋(Small Dataset)에 해당합니다.

- **LightGBM:** 데이터 수가 적을 때 과적합(Overfitting)에 매우 취약합니다. (보통 최소 10,000개 이상의 행이 있을 때 성능이 발휘됩니다.)

- **XGBoost:** 과적합 방지를 위한 규제(L1, L2 Regularization) 파라미터가 잘 구축되어 있어 소규모 데이터에서도 안정적인 성능을 보입니다.
- **CatBoost:** 내부적인 대칭 트리(Symmetric Tree) 구조와 순차적 부스팅(Ordered Boosting) 덕분에 기본 파라미터 설정만으로도 데이터가 적을 때 매우 뛰어난 일반화 성능을 냅니다.

---

3. 최적 추천 및 이유

✅ **최적 추천: CatBoost (또는 규제를 적용한 XGBoost)**
이유:

1. **소규모 데이터 과적합 방지:** 약 700여 개의 데이터는 머신러닝 모델이 쉽게 과적합되기 쉬운 크기입니다. CatBoost는 구조적으로 과적합을 매우 강력하게 방지하도록 설계되어 있어 데이터가 적은 환경에서 가장 안정적입니다.
2. **결측치 자동 처리 최적화:** 굳이 인위적인 중앙값 대치로 인해 `Spike` 현상을 만들 필요 없이, `NaN` 상태 그대로 입력해도 최적의 분할 방향을 스스로 학습합니다.
3. **파라미터 튜닝 부담 최소화:** 튜닝을 많이 거치지 않은 기본 상태(Default)에서도 소형 데이터셋에 대해 3가지 모델 중 가장 뛰어난 예측 성능을 보여줍니다.

요약

- **모델 특징:** XGBoost, LightGBM, CatBoost 모두 `NaN`을 손실 감소량이 큰 최적 노드로 자동 분할하는 기능 제공.
- **상황 판단:** 700여 개 행의 소규모 데이터에서는 과적합 위험이 높은 LightGBM보다는 **CatBoost** 또는 **XGBoost**가 적합.
- **최적 선택:** 소형 데이터셋에서 과적합 방지 성능과 결측치 자동 처리 능력이 가장 뛰어난 **CatBoost**를 채택하는 것을 추천.